Transformer 의 한계 및 연구동향 분석을 통한 Post-Transformer 발전 방향 제언

Gemma 3N E4B 실측 기반 Decode 병목 분석

김현우 · 김민솔 · 김진희

삼육대학교 인공지능융합학부 | 2026.04 | 중간발표

주제 선정 이유

MLP → CNN → Attention

↓

transformer

주제 선정 이유

Transformer

Claude

병목은 어디인가?

Attention 연산?

Memory Access?

직접 측정해서 확인했습니다.

실험 환경

모델	Gemma 3N E4B (GQA 4:1, 35 layers)
양자화	W4A32 (가중치 INT4, 활성화 FP32)
HW	AMD Ryzen 5 4500U + 16GB LPDDR4X
엔진	llm-lite (자체 C++/Vulkan 구현)
측정	Input ~30 tok → Output 88 tok, warm-up 후 1회

한계: 단일 모델 · 단일 HW 사례 연구 | baseline 비교는 후속 과제

실험 결과: bottleneck

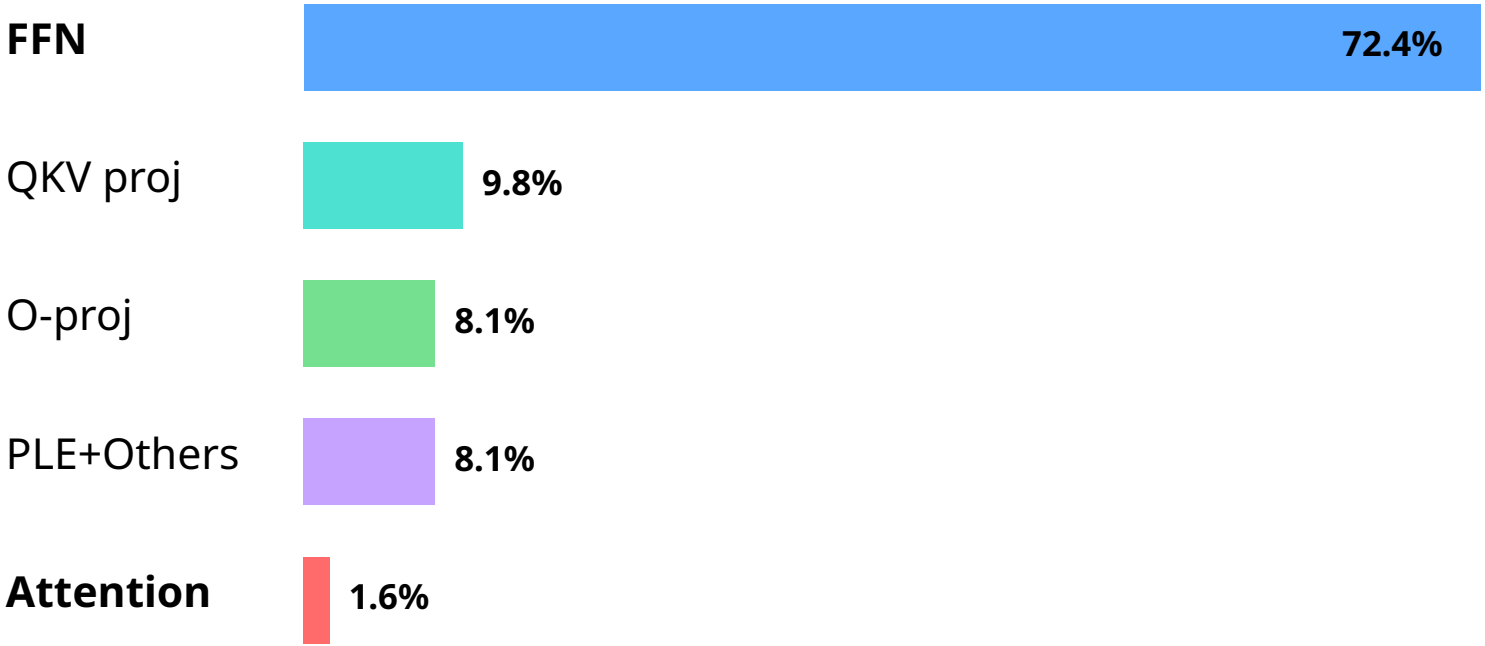

SLM에서 Attention이 병목이 아니었다.

FFN + Linear Projection = 90%

Attention = 1.6%

병목 완화 ① 양자화

Weight Quantization

AWQ

salient 1% weight 보호 → 대표적인 INT4 PTQ 기법

BitNet b1.58

가중치 = {-1, 0, +1} → 곱셈 → 덧셈/뺄셈으로 단순화

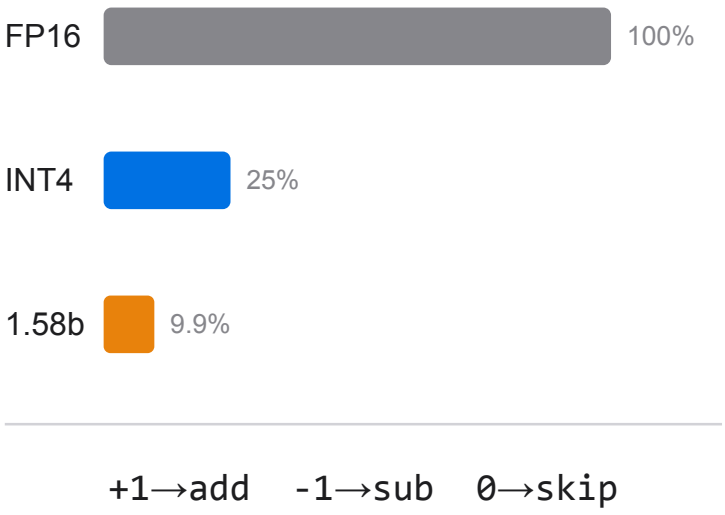

가중치가 작아지면 매 토큰마다 DRAM에서 읽는 양이 줄어든다

병목 완화 ②③ KV-cache 압축 & 구조 변경

KV-cache 압축

KIVI — 비대칭 2-bit → 2.6x 절감

TurboQuant — 3.5 bits, 품질 저하 거의 없음 보고

공통 목표: memory traffic 최소화

근본적 원인 해결이 아니다.

Post - Transformer ?

인간의 개입 없이 학습하고 개선하는 방법론

AlphaEvolve

평가 가능한 최적화 문제의 자동 탐색

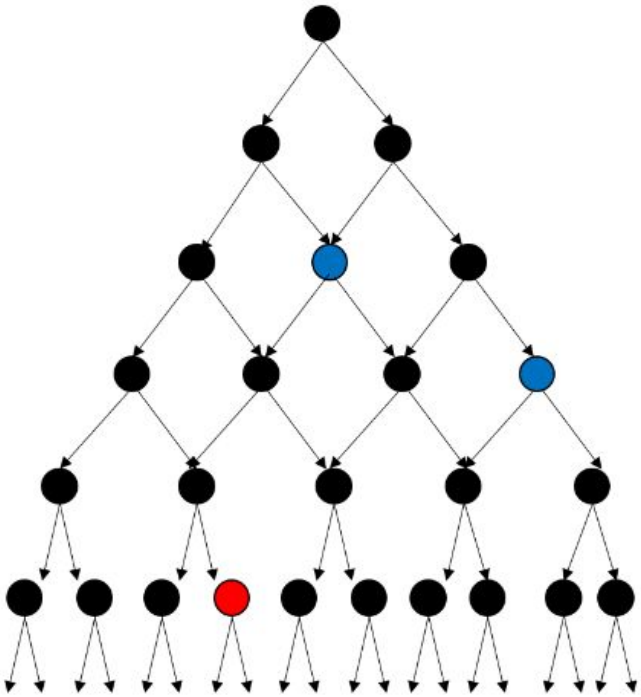

AlphaEvolve

평가 가능한 최적화 문제의 자동 탐색

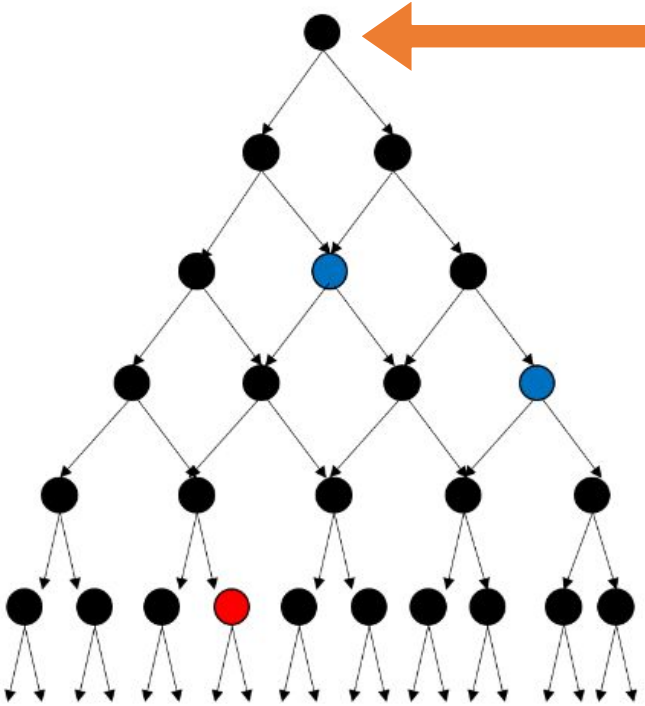

```
for (int R = 0; R < ROW; R++){
    for (int C = 0; C < COL; C++){
        'task…'
    }
}
```

AlphaEvolve

Reversed

```
for(int R=ROW-1; R >=0; R--){
    for(int C=COL-1; C >=0; C--){
        'task…'
    }
}
```

Original

```
for (int R = 0; R < ROW; R++){
    for (int C = 0; C < COL; C++){
        'task…'
    }
}
```

C++ & R++ -> ++R & ++C

```
for(int R = 0; R < ROW; ++R){
    for(int C = 0; C < COL; ++C){
        'task…'
    }
}
```

C++ -> ++C

```
for (int R = 0; R < ROW; R++){
    for (int C = 0; C < COL; ++C){
        'task…'
    }
}
```

AlphaEvolve

평가 가능한 최적화 문제의 자동 탐색

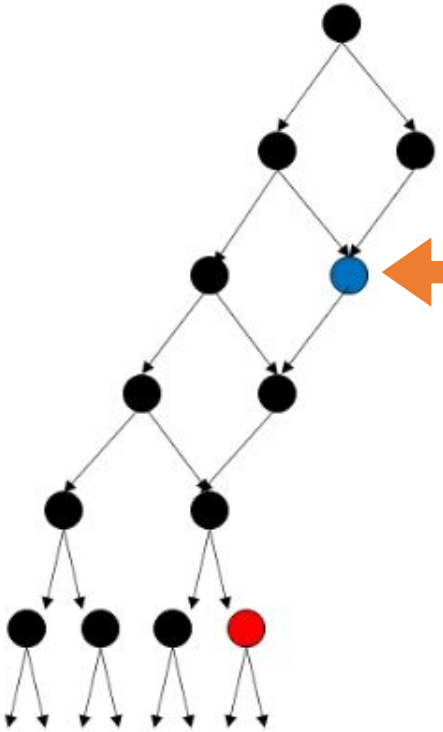

```
for (int R = 0; R < ROW; R++){
    for (int C = 0; C < COL; C++){
        'task…'
    }
}
```

AlphaEvolve

평가 가능한 최적화 문제의 자동 탐색

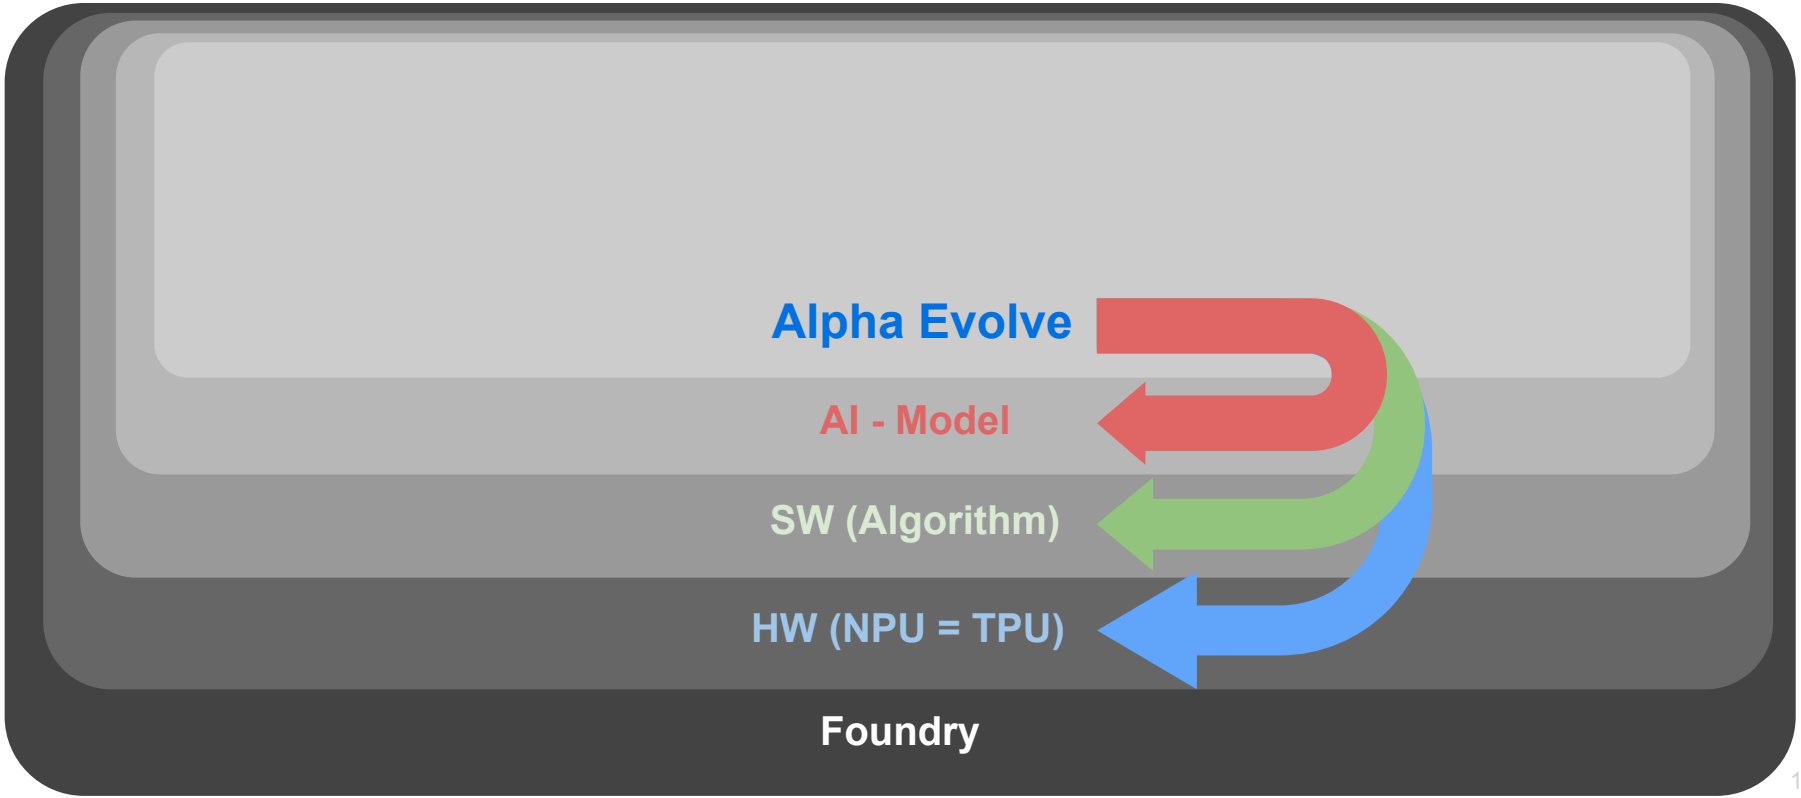

AlphaEvolve

평가 가능한 최적화 문제의 자동 탐색

문제 정의 → 코드 생성 → 실행·평가 → 선택·변형 → 반복

56년

Strassen 최초 개선

32.5%

FlashAttention 가속

TPU

Verilog 회로 수정

Generate → **Run** → **Score** → **Select** → **Mutate** → **Generate**

Works only when evaluator exists

결론

Alpha Evolve 와 같은 AI가 인간의 개입 없이 스스로를 발전시키는 방법론이 핵심 주제로 떠오를 것이다.

Post-Transformer는 인간이 아닌 AI가 만들 것이다.

Q & A

김현우 · 김민솔 · 김진희